

火山引擎大模型调试指南

----基于 SC171 开发套件 V3

文档版本：V2.0

更新时间：2026 年 1 月 15 日

适用型号

序列	文档版本	适用型号	更新说明
1	1.0	SC171 开发套件 V3	适用于 2025 年火山引擎官网
2	2.0	SC171 开发套件 V3	适用于 2026 年火山引擎官网

目录

1 实验内容..... 1

2 实验原理..... 1

3 实验步骤..... 2

4 实验结果..... 7

1 实验内容

1. 掌握火山引擎 AI 网关 API 的规范调用方法，包括密钥配置、请求参数构建及响应解析逻辑
2. 完成在 SC171 开发套件 V3 端侧环境搭建，实现对火山引擎大模型的稳定调用。
3. 在 SC171 开发套件 V3 上部署完整对话工程，支持多轮对话、对话历史管理及流式/非流式输出切换。

2 实验原理

1. 火山引擎 AI 网关

火山引擎 AI 网关是基于深度学习技术的大语言模型服务平台，提供多种先进的大模型 API 接口。豆包大模型是火山引擎自主研发的大语言模型，具备强大的自然语言理解和生成能力，支持多轮对话、文本生成、问答等多种应用场景。

2. 大模型对话系统构建流程

配置加载：优先读取代码参数，忽略配置文件参数的覆盖。

API 认证：使用申请到的 API 密钥生成认证信息，网关校验通过后，建立连接。

请求构建：自动整合用户输入与对话历史，按模型要求设置 `temperature`、`max_tokens` 等参数。

模型调用：根据代码中设置，选择流式/非流式调用模式，通过 HTTPS 协议向火山引擎 AI 网关发送请求。

响应处理：分为流式输出与非流式输出，流式输出逐段接收模型回复并实时打印，避免因网络波动导致的输出中断；接收并解析模型返回的对话响应内容，非流式输出接收完整响应后返回的对话响应内容。

对话管理：自动保存对话历史至内存，支持 `/save`、`/history` 等命令，实现多轮对话上下文关联。




图 2-1 大模型对话系统构建流程图

3 实验步骤

1. 环境准备


- (1) 硬件环境：个人 PC、SC171 开发套件 V3
- (2) 软件环境：VS Code

2. 火山引擎大模型案例实战

(1) API 密钥申请与配置

进入火山引擎官网，注册账号并登录：

<https://console.volcengine.com/vei/aigateway/overview>



登录成功后，点击“立即创建”



选择后付费密钥，点击“开始创建”



点击同意协议，再点击“立即购买”

< 边缘大模型网关后付费密钥

产品介绍 边缘大模型网关支持通过一个API接口访问多家大模型提供商的模型与智能体。依托边缘架构优势,边缘大模型网关显著提升模型访问速度,通过语义能力机制减少模型请求回源次数,为终端用户提供更快、更可靠的AI服务体验。您可以通过边缘大模型网关平台部署模型与智能体,也可以调用您在第三方AI平台的模型与智能体。详情查看 [产品介绍](#)。

计费说明 后付费密钥下,您可以创建网关密钥并关联多个模型,系统将根据各模型的实际调用量独立计算费用。详情查看 [产品计费说明](#)。

创建后付费密钥

计费类型 [后付费按量计费](#)

标签 [+ 添加标签](#) 还可添加20个

所属项目 [选择](#)

将单个云账号下多个地域的多种云资源归类到不同的项目,可用于管理资源

用量类型 [Token用量](#) [字符数](#) [调用次数](#) [语音时长](#)

☒ 我同意 [《边缘大模型网关产品服务协议》](#)

配置费用 0 元

[取消](#) [立即购买](#)

点击“提交”


1 确认订单信息 2 提交支付信息 3 支付完成

参数配置

订单类型	产品	配置详情	付款方式	购买时长	数量	原价
新购	边缘大模型网关	通用密钥AI服务调用 (后付费)	后付费	-	1	¥

[提交](#)


提交成功, 点击“去控制台”




如下图所示, 密钥创建成功



点击密钥名称，完善密钥配饰，点击“立刻编辑”



配置模型，点击“新增模型”，自行选择想要调用的模型



如下图所示添加成功，点击“下一步：调用配置”



根据个人需求来调整对应配置信息，并保存配置信息

编辑网关访问密钥

重试次数 当一个模型或智能体调用失败后，网关将重新尝试调用此模型，直到重试次数耗尽。重试次数取值范围：0（不重试）~3。

高级配置

缓存启用状态 ☐

请求超时定义 毫秒
请根据所选模型/智能体类型与使用场景，合理配置请求超时。在深度思考（Reasoning）等类型的模型使用场景下，模型调用耗时可能会偏长。

请求速率限制

渠道类型	HTTP 协议	WebSocket 协议
平台预置模型/智能体	请求次数 10 次/分钟 10个生效对象	活跃链接数 5 个 0个生效对象

密钥创建成功，可以查看对应请求地址与密钥信息

火山引擎 总览 账号全部资源 搜索产品或文档 企业 工具 费用 支持 备案

边缘大模型网关

网关访问密钥管理 > 网关访问密钥详情

边缘大模型网关后付费密钥20250826 使用中

基本信息 调用策略 用量统计

基本信息

名称	边缘大模型网关后付费密钥20250826	计费类型	后付费
ID	AI_Gateway2000000343421295842	描述	-
创建时间	2025-08-26 16:43:23		

请求方式

请求地址	https://ai-gateway.vei.volces.com	密钥	查看密钥
调用示例	查看代码		

（2）端侧模型推理

- ① 将所需的工程源码文件放入 SC171 开发套件 V3
- ② 打开终端，进入该路径下的终端，输入命令：

```
pip3 install openai configparser
```

根据个人相关信息进行修改相关配置区域，需要准备的参数：

--api_key: 用于身份验证的密钥

--base_url: API 服务地址

--model: 选择的大模型名称

调用 sample 执行文件进行推理，在开发板终端输入以下命令：

```
python3 <Python sample 文件地址>
```

如：

```
python3 /home/fibo/project/main.py
```

如下图所示，程序启动后，可以在终端输入问题与大模型进行对话。

```
API客户端初始化成功
新对话已开始 - 2025-09-03 07:55:16
系统提示: You are a helpful and knowledgeable assistant.
当前模型: doubao-1.5-lite-32k
-----

当前配置 (代码配置区域供查阅最高):
- API密钥: sk-1d68a8f...2c1yh
- 基础URL: https://ai-gateway.wei.volces.com/v1
- 默认模型: doubao-1.5-lite-32k
- 系统提示: You are a helpful and knowledgeable assistant...
- 最大token数: 3000
- 温度参数: 0.7
- 流式输出: 启用
- 对话保存目录: conversations
- 彩色输出: 启用

可用命令:
/help          - 显示此帮助信息
/history [n]   - 显示对话历史 (可指定显示最近n条)
/save [name]   - 保存对话到文件 (可指定文件名)
/load <name>   - 从文件加载对话
/list         - 列出所有对话文件
/stats        - 显示对话统计
/model <name> - 更改模型
/models       - 显示可用模型列表
/config       - 显示当前配置
/clear        - 开始新对话 (清空历史)
/export [fmt] - 导出对话为文本格式 (txt/md)
/stream on/off - 开启/关闭流式输出
/quit        - 退出程序

提示: 输入内容与AI对话, 空行重新显示提示符
-----

您: 你好
AI: 你好! 有什么我可以帮忙的吗? 无论是询问信息、寻求建议, 还是只是想聊天, 都可以随时和我交流哦。
```

图 3-1 输出结果

4 实验结果

1. 部署大模型对话系统于边缘计算设备 SC171 开发套件 V3, 明确代码内容, 完整记录系统从问题输入、模型处理到回复输出的全流程。
2. 对系统进行实时测试, 响应时间测试, 验证上下文保持能力。设计连续对话场景。不同模型对比测试。